

Shortlisted tokenizer cost by dialect

Candidate

byte_bpe_balanced_16k

0.697

0.685

0.688

0.677

0.685

0.695

0.690

0.673

0.715

0.683

0.699

0.687

0.684

unigram_balanced_32k

0.225

0.241

0.250

0.239

0.216

0.239

0.237

0.230

0.239

0.245

0.217

0.244

0.227

wordpiece_balanced_32k

0.209

0.231

0.235

0.224

0.203

0.225

0.225

0.213

0.215

0.231

0.203

0.238

0.212

wordpiece_natural_32k

0.210

0.226

0.235

0.222

0.203

0.224

0.229

0.214

0.217

0.231

0.202

0.234

0.214

BAR

CHI

KHU

KIS

MYM

NAR

NOA

NSD

RAJ

RAN

STD

SYL

TAN

Dialect

tokens/character

0.7

0.6

0.5

0.4

0.3